HW2 多元線性迴歸：洪水機率資料的確定性規則與特徵選擇

學號：7114056126｜GitHub：benson103081｜分析日期：2026-10-18

版本狀態：分析、程式、圖表與網站已製作；NotebookLM 實際研究摘要及完整 GPT 對話 PDF 尚待使用者補上。此報告不是已齊備所有必交附件的最終版本。

摘要

本研究使用 Kaggle Flood Prediction Dataset 版本 1 的 50,000 筆資料與 20 個數值特徵，依 CRISP-DM 建立可重現的多元線性迴歸流程。資料以固定亂數種子切為 40,000 筆訓練與 10,000 筆測試，前處理和特徵選擇均在交叉驗證訓練折內完成。完整 OLS 的測試 R^2 為 1；事後以十進位精確運算核對發現，全部目標都等於 20 個輸入分數加總除以 200。研究價值在於揭露資料的確定性規則、解釋刪除特徵的誤差，以及避免將完美擬合誤認為真實災害預測能力。

1. Business Understanding｜商業理解

情境：若取得環境與社會因素評分，能否預測 FloodProbability？能否用較少欄位維持表現？主要比較標準為訓練集五折 CV RMSE，測試集用於最終評估。將預測訓練平均值設為最低基準，並比較解釋性較高的線性模型與非線性樹模型。資料沒有真實時空識別、感測器量測或事件標籤證據，因此成果定位為分析教學，不作預警、保險定價或因果政策建議。

2. Data Understanding｜資料理解

來源：Naiya Khalid，Flood Prediction Dataset，https://www.kaggle.com/datasets/naiyakhalid/flood-prediction-dataset。下載固定 datasetVersionNumber=1 的 flood.csv；查詢當日公開中繼資料為版本 2，但本研究固定使用版本 1，避免無聲改變資料。公開 listing 標示 CC0: Public Domain，並保留 source.json 作來源紀錄。資料不是後來百萬筆的 Playground 競賽衍生資料。

SHA-256：9cf6a2339d7c7524620f99497801c278e3c1ed0aca8d0fde22a683508fa10e8d

實際檢查：50,000 筆、21 欄（20 個輸入 + 1 個目標）；缺值合計 0，完全重複列 0。全部欄位為數值型；目標介於 0 與 1。除原始檔品質檢查外，特徵分布與相關性僅由訓練資料計算。

欄位（原始名稱）	中文輔助標籤	訓練最小 – 最大	訓練平均
MonsoonIntensity	季風強度	0 – 16	4.991
TopographyDrainage	地形排水	0 – 18	4.975
RiverManagement	河川管理	0 – 16	5.015
Deforestation	森林砍伐	0 – 17	5.014
Urbanization	都市化	0 – 17	4.989
ClimateChange	氣候變遷	0 – 16	4.994
DamsQuality	水壩品質	0 – 15	5.012
Siltation	淤積	0 – 16	4.989

欄位（原始名稱）	中文輔助標籤	訓練最小 – 最大	訓練平均
AgriculturalPractices	農業活動	0 – 16	5.004
Encroachments	土地侵占	0 – 18	5.012
IneffectiveDisasterPreparedness	災害準備不足	0 – 16	5.003
DrainageSystems	排水系統	0 – 17	5.011
CoastalVulnerability	海岸脆弱度	0 – 17	5.005
Landslides	山崩	0 – 14	4.980
Watersheds	集水區	0 – 16	4.983
DeterioratingInfrastructure	基礎設施劣化	0 – 17	4.993
PopulationScore	人口分數	0 – 19	4.980
WetlandLoss	濕地流失	0 – 17	5.006
InadequatePlanning	規劃不足	0 – 16	4.999
PoliticalFactors	政治因素	0 – 16	4.995

中文名稱是欄位翻譯，不補造來源未提供的單位或分數方向。例如 DamsQuality 的正係數不能解讀為「水壩品質越好越會淹水」。

3. Data Preparation｜資料準備

先移除完全重複列與缺少目標列，再使用 train_test_split(test_size=0.2, random_state=711405612)。訓練資料內以 KFold(5, shuffle=True, random_state=711405612) 建立共用折。每折的 SimpleImputer(median)、StandardScaler、特徵選擇與模型都置於 Pipeline；不以驗證或測試資料擬合。資料沒有類別欄，因此不需要 one-hot encoding。未刪除極端值，以免任意改變分布。原始 CSV 列號及每折驗證位置保存在 reports/splits.json。

4. Modeling｜建模與特徵選擇

完整 OLS 含截距，最小化殘差平方和。Ridge 使用 L2 懲罰，alpha = 0.01、1、100、1000；Lasso 使用 L1 懲罰，alpha = 10^-6、10^-5、10^-4、10^-3、10^-2，max_iter=20000、tol=10^-9。StandardScaler 只標準化 X，未標準化 y；兩種模型的 alpha 定義不同，不直接比較其數字大小。

SelectKBest 用訓練折內的單變量 f_regression 分數選欄；RFE 以標準化後的線性係數遞迴剔除，每次移除 1 欄。兩者均測試 k=5、10、14、16、18、20，之後擬合 OLS。額外的 Histogram Gradient Boosting 設 max_iter=200、max_leaf_nodes=15 或 31、early_stopping=True，只在訓練折內早停。七個方法共用相同五折；GridSearchCV 依平均 CV RMSE 選參數。

預測模型在讀取測試成績前依 CV 鎖定。完整 OLS 與選滿 20 欄的選擇器本質上是同一模型；近乎零的誤差差異只反映浮點運算，不宣稱存在實質優劣。CV 參與調參，最佳 CV 分數仍有選擇偏差；測試資料才是留出評估。

方法	最佳參數	CV RMSE	測試 RMSE	測試 R^2
Mean baseline	{}	0.050089	0.0498141	-0.000101464
OLS	{}	6.09953e-16	1.79618e-16	1

方法	最佳參數	CV RMSE	測試 RMSE	測試 R^2
Ridge	{'model__alpha': 0.01}	1.56115e-08	1.24116e-08	1
Lasso	{'model__alpha': 1e-06}	4.46837e-06	4.44086e-06	1
SelectKBest + OLS	{'select__k': 20}	6.09953e-16	1.79618e-16	1
RFE + OLS	{'select__n_features_to_select': 20}	6.09953e-16	1.79618e-16	1
Histogram boosting	{'model__max_leaf_nodes': 31}	0.00916137	0.00877118	0.968993

方法	測試 MAE	測試 MSE	訓練 Adjusted R^2
Mean baseline	0.0397817	0.00248145	不適用
OLS	1.40221e-16	3.22626e-32	1
Ridge	9.91455e-09	1.54048e-16	不適用
Lasso	3.54739e-06	1.97212e-11	不適用
SelectKBest + OLS	1.40221e-16	3.22626e-32	1
RFE + OLS	1.40221e-16	3.22626e-32	1
Histogram boosting	0.00677832	7.69336e-05	不適用

RMSE=sqrt(mean((y − ŷ)^2))，MAE=mean(|y − ŷ|)，MSE=mean((y − ŷ)^2)，$R^2 = 1 - SSE/SST$。Adjusted $R^2 = 1 - (1 - R^2)(n-1)/(n-p-1)$，只呈現非正則化 OLS 的訓練描述值；特徵選擇後的此數字不作未經調整的統計推論。

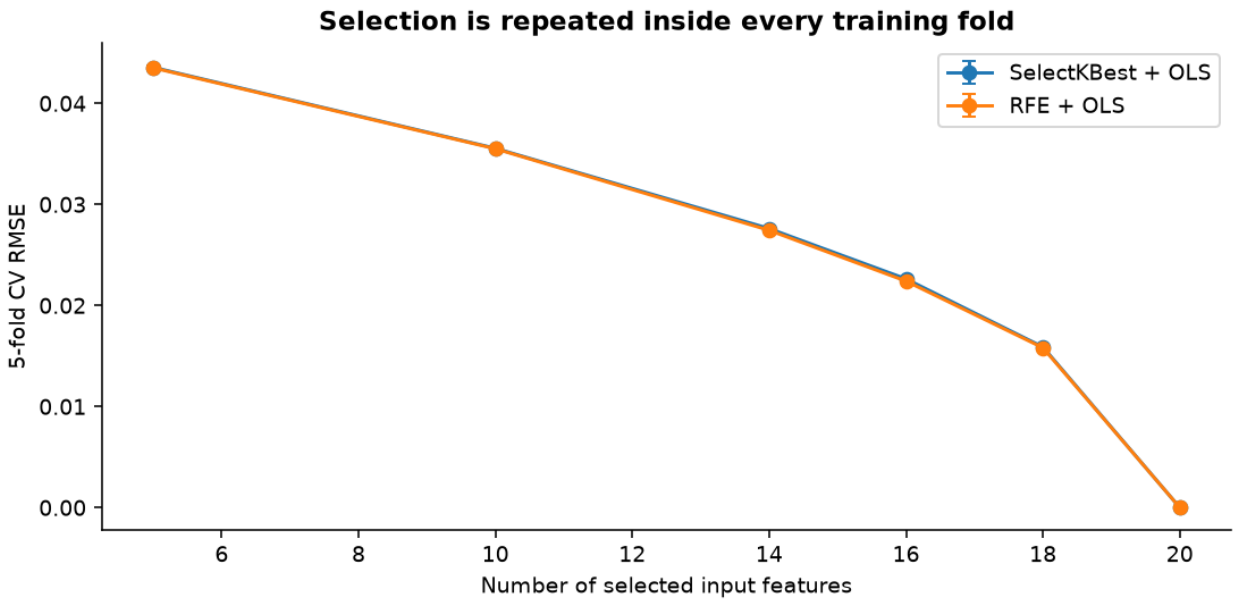


圖 1：特徵選擇曲線，誤差棒為五折分數標準差；並非信賴區間。

選擇方法	保留 14 欄的 CV RMSE	保留 20 欄的 CV RMSE
SelectKBest + OLS	0.0276054	6.09953e-16
RFE + OLS	0.0274325	6.09953e-16

5. Evaluation｜評估與結果解釋

重要發現：訓練完成後，使用 Python Decimal 以 CSV 原始十進位字串逐筆核對：FloodProbability = (MonsoonIntensity + … + PoliticalFactors) / 200。50,000 / 50,000 筆完全相等，最大十進位誤差為 0。此稽核沒有用來訓練或調參，只用於解釋異常高分。這支持「所提供資料存在確定性目標公式」，但不能單憑公式斷言作者如何收集或生成資料。

因此每個輸入分數的原始尺度 OLS 係數約為 0.005，截距約為 0。完整模型重建公式，R^2 =1 與近零 RMSE 是合理數值結果；刪掉任何有變動的因素就失去公式資訊，故兩種選擇器都選滿 20 欄。沒有為了展示「特徵選擇成功」而強制保留較少欄位。

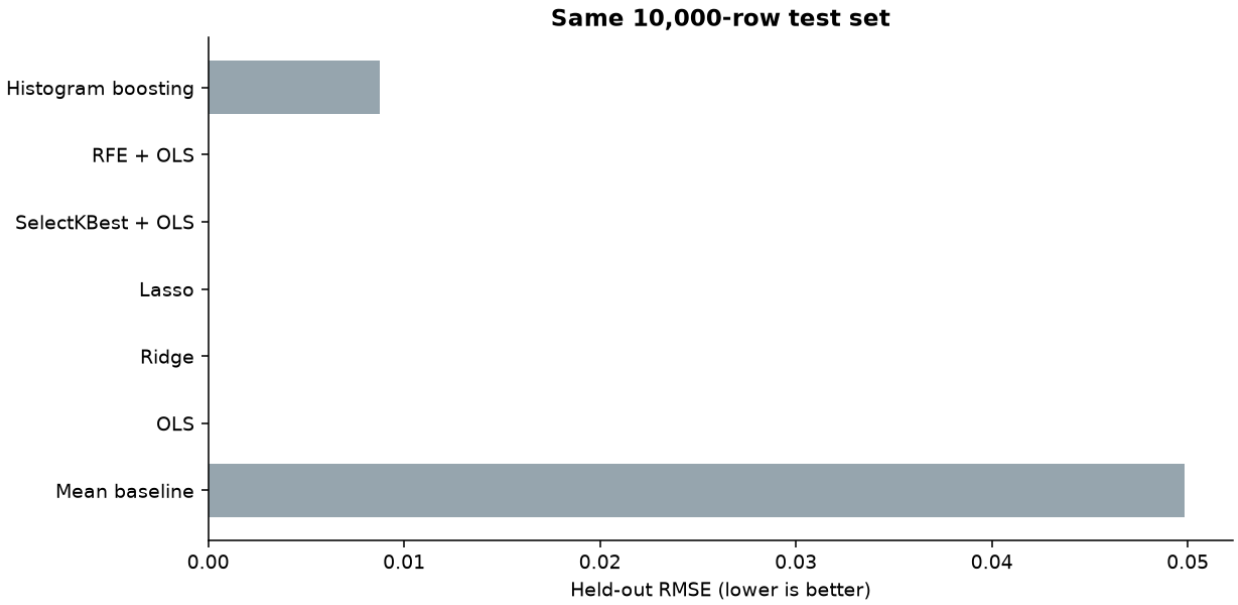


圖 2：獨立測試集誤差；樹模型沒有優於本資料的確定性線性公式。

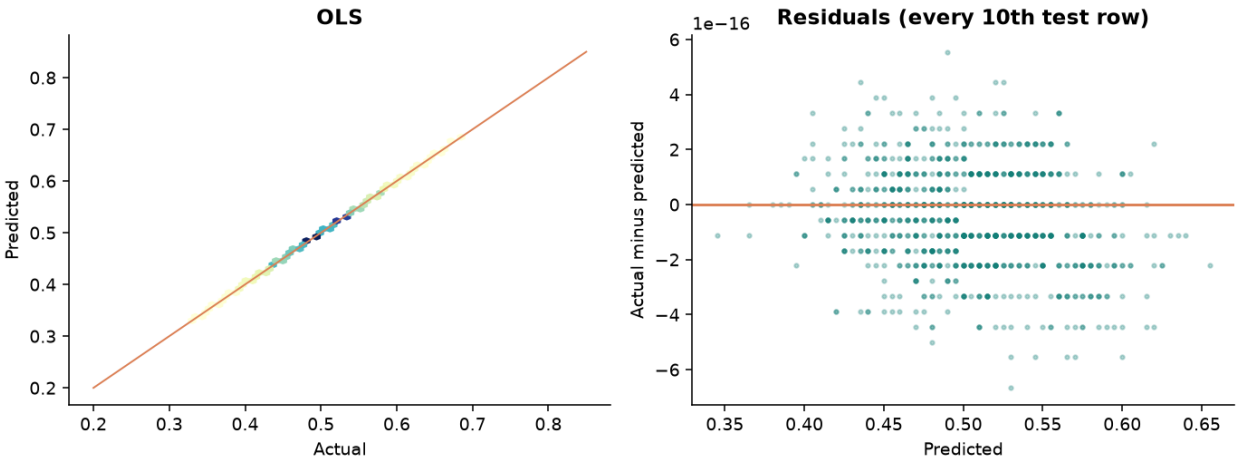


圖 3：實際值／預測值及殘差；殘差尺度接近機器精度，不代表測量誤差如此小。

五項假設診斷

線性：逐筆精確公式及圖形支持本表內的線性關係。共線性：完整 OLS 最大 VIF = 1.000767，沒有顯著共線性跡象。獨立性：缺乏時間、地點或群組資訊，無法確認，不能用打亂順序後的 Durbin – Watson 宣稱通過。

等變異與殘差常態：完整模型殘差只剩浮點運算誤差；RESET、Breusch – Pagan、Jarque – Bera 與 Durbin – Watson 的數值無法作為有意義的統計證據，結果欄設為不適用。原始計算值只保存在 numerical_only_do_not_interpret 供稽核。一般 OLS 預測區間會退化為近乎零寬，故網站與報告不提供誤導性的 95% 區間；題目要求的預測圖已完整提供。

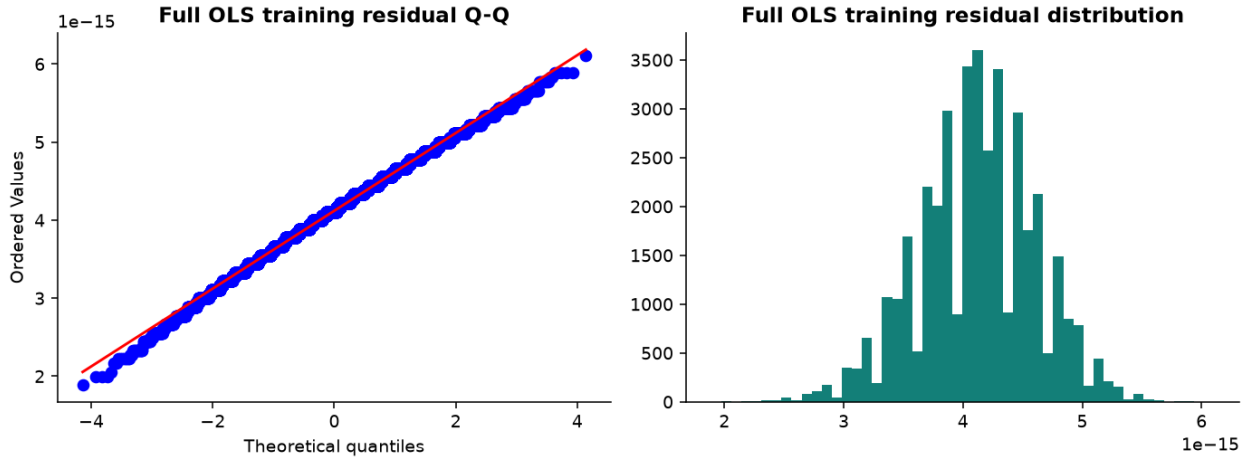


圖 4：Q-Q 與殘差分布只展示浮點誤差形狀，不進行常態推論。

網路主流或更優方法的比較

依 scikit-learn 官方線性模型與特徵選擇說明，Ridge、Lasso、單變量篩選及 RFE 是本研究比較的方法；Lasso 可產生稀疏係數，Ridge 通常不會精確歸零。另依官方 ensemble 文件，直方圖梯度提升可擬合表格資料的非線性。本研究已在相同切分實跑該方法，其測試 RMSE 約 0.00877、R^2 約 0.969，未超越完整 OLS。這只適用本次參數網格及資料，不代表線性模型普遍優於 boosting。未引用他人的 Kaggle 排名或把不同資料上的成績當作公平比較。

可行的下一步是取得有地點、時間與真實觀測定義的獨立資料，再評估時間／區域外推與機率校準；若確有非線性，可擴大樹模型調參範圍或比較其他方法。對現有確定性資料，追求更複雜模型不能改善實際科學效度。沒有參加 Kaggle 競賽，因此沒有名次；不提供虛構排名。

6. Deployment｜部署與重現

主程式：7114056126_hw2.py。安裝 requirements.txt 後執行主程式，產生模型比較、切分列號、測試預測及圖表，再執行 python scripts/build_report.py 建立報告。網站使用 JSON 中的原始尺度係數，計算 $\hat{y}$ = intercept + Σ coefficient_i × input_i；20 個輸入支援滑桿與數字、模型切換、重設與示範情境。超出訓練範圍時提醒外推，空白或非法輸入不計算。

數值驗證：以 statsmodels 獨立 OLS 對照 scikit-learn 預測；所有匯出的線性係數以原始測試列重算，要求絕對誤差小於 10^-12。另以 Decimal 核對確定性公式。網站瀏覽器測試和最終部署狀態請見 reports/browser-verification.json 與 README；未完成的連線或人工附件會另列，不把預計網址視為已成功部署。

7. GPT 輔助內容

本作業由使用者提出需求並提供學號與繳交規格，GPT/Codex 協助閱讀題目、查詢來源、撰寫程式、設計分析流程、製作網站、查核數值及整理報告。全部模型分數由實際下載資料執行產生，未將範例成績抄入報告。使用者需審閱結論並理解程式；AI 協助不取代資料來源可信度或個人責任。

待附：完整 GPT 對話 PDF。必須由使用者從聊天介面匯出此次作業的所有對話；不能以本節摘要冒充完整對話紀錄。

8. NotebookLM 研究摘要（待使用者完成）

此環境沒有可用的 NotebookLM 連線，因此尚未執行 NotebookLM 研究，也未撰寫冒充其輸出的摘要。請依「需要你完成的事項.txt」加入來源、執行提問，將實際回覆及來源資訊保存；再完成至少 100 字繁體中文摘要放入本節，明確標示 NotebookLM 摘要。

9. 參考來源

Kaggle 資料來源：https://www.kaggle.com/datasets/naiyakhalid/flood-prediction-dataset

scikit-learn：Linear Models：https://scikit-learn.org/stable/modules/linear_model.html

scikit-learn：Feature selection：https://scikit-learn.org/stable/modules/feature_selection.html

scikit-learn：Common pitfalls / leakage：https://scikit-learn.org/stable/common_pitfalls.html

scikit-learn：Histogram-based gradient boosting：https://scikit-learn.org/stable/modules/ensemble.html#histogram-based-gradient-boosting

statsmodels：Regression diagnostics：https://www.statsmodels.org/stable/diagnostic.html

來源查閱日期：2026-10-18。方法介紹採官方文件；資料生成規則為本次實測發現，未宣稱由 Kaggle 作者確認。